

Описание датасета

Для формирования обучающей выборки были использованы следующие подходы:

1. Были выполнены аудиозаписи чтения классического текста “Как я ловил раков” [Корнев А. Н. Нарушения чтения и письма у детей: Учебно-методическое пособие. – СПб.: ИД “МиМ”, 1997. – 286 с.]
 - 1.1. здоровыми детьми,
 - 1.2. детьми с клиническим диагнозом “дислексия”,
 - 1.3. автоматическими системами генерации аудиопотоков (Текст предлагался к прочтению различным online-системам «Текст в голос», в том числе <https://voxworker.com/ru> с различными голосами озвучки, скоростью и высотой голоса; для придания большей естественности текст был промаркирован символами паузы и ударения (см. в репозитории tasks/raki-punk.txt).
2. Отдельные записи произнесения детьми слов с буквой “р” были вручную разделены логопедом на два класса: с хорошим произношением “р” и с плохим произношением “р”.
3. Выполнены самостоятельно и собраны записи чтения детьми отрывков художественных текстов, скороговорок.

Был собран набор датасетов общим объемом более 1 ГБ (аудио + соответствующие тексты), структурированный следующим образом:

	Содержание раздела датасета	Ссылка на данные	Описание
1	Образцы чтения текста “Как я ловил раков”		Корнев А. Н. Нарушения чтения и письма у детей: Учебно-методическое пособие. – СПб.: ИД “МиМ”, 1997. – 286 с.
1.1	читают здоровые дети	https://huggingface.co/datasets/dysata/raki	Аудиофайлы размещены в каталоге https://huggingface.co/datasets/dysata/raki/tree/main/data , метаданные (информация об аудио) находятся в файле https://huggingface.co/datasets/dysata/raki/blob/main/metadata.csv , в котором для каждого аудиофайла имеется запись (строка) следующей структуры: <путь к аудиофайлу>,
1.2	читают дети с диагностированной дислексией		

1.3	чтение автоматическими системами генерации текст-в-аудио		<пол>, <возраст>, <read>, <тип_читателя>, <прочитанный текст>. Используются следующие коды. Пол читателя: 0 – мужской, 1 – женский. Возраст: целое число, если известен, в противном случае 0 или -1. Тип читателя: 1 – дислексик, 0 – здоровый, -1 – автоматический генератор текст-в-аудио, 2 – взрослый здоровый. Read – 1 чтение с текста, 0 – чтение по памяти.
2	Две группы записей с хорошим и плохим произношением “р” детьми	https://huggingface.co/datasets/dysata/rwords	В каталоге https://huggingface.co/datasets/dysata/rwords/tree/main/good размещены аудиофайлы (формат WAV) произношения слов с хорошим выговариванием “р”. В каталоге https://huggingface.co/datasets/dysata/rwords/tree/main/notgood размещены аудиозаписи произношения слов с нарушениями выговаривания “р”. Имя файла содержит в себе читаемое слово в последней позиции после знака подчеркивания перед точкой в расширении файла: <некоторая буквенно-численная строка>_<номер>_<произносимое слово>.wav
3	Чтение детьми отрывков художественных текстов и соответствующие транскрипции, а также скороговорок	https://huggingface.co/datasets/dysata/childread001	Аудиофайлы размещены в каталоге https://huggingface.co/datasets/dysata/childread001/tree/main/data , метаданные (информация об аудио) находятся в файле metadata.csv, в котором для каждого аудиофайла имеется запись (строка) следующей структуры: <путь к аудиофайлу>, <пол>, <возраст>, <прочитанный текст>. Используются следующие коды. Пол читателя: 1 – мужской, 0 – женский, -1, если не указан. Возраст: целое число, если известен, в противном случае -1. В каталоге https://huggingface.co/datasets/dysata/childread001/tree/main/transkript размещены читаемые тексты в файлах с соответствующими названиями.