

Обучение моделей

1 Дообучение нейросетевой модели wav2vec2

Для улучшения распознавания детских голосов было проведено дообучение wav2vec2 на корпусе детского чтения. Характерный пример скрипта, использовавшегося для обучения, приведен в файле model/train/tr.py в репозитории кода проекта <https://github.com/dysata/dyslexia-child>, в котором реализован классический подход для дообучения w2v. Дообученная модель выложена на Hugging Face <https://huggingface.co/dysata/Wav2Vec2-Ru-Child>. Поскольку модель обучалась этапами и дообучается на растущем корпусе, то на Hugging Face выкладываются и обновленные модели с индексом vXX.

2 Обучение модели градиентного бустинга на деревьях решений CatBoost

Одна из целей использования модели на CatBoost заключается в том, чтобы на небольших датасетах, которые пользователь библиотеки может сам сформировать, например, с помощью веб-приложения для сбора и разметки данных или с помощью калибровочных записей корректного произношения слов, например, по картинкам проводить более корректное распознавание звуков, которые в wav2vec2 относятся к одному лейблу (фонеме/паузе). Для этого из wav2vec2 извлекается последний скрытый слой и классифицируется внешним классификатором CatBoost. В качестве примера для определения качества произношения Р был сформирован небольшой датасет, который был размечен логопедами на хорошее и плохое произношение Р <https://huggingface.co/datasets/dysata/rwords>, затем датасет был проанализирован wav2vec и отсортированы те логиты, в которых высокое совпадение с лейблом Р и для хорошего и для плохого произношения. Т.е. это та ситуация, в которой wav2vec их не различает. И для этого датасета было проведено обучение catboost классификатора. Для логопедических задач на тренировку качества произношения Р можно заменить классификатор на регрессор. Характерный скрипт обучения представлен в файле model/train/train_catboost80.py в репозитории кода проекта <https://github.com/dysata/dyslexia-child>. Характерный пример формирования датасета в файле parquet с разметкой в поле "a" 1 или 0 для хорошего или плохого произношения формируется в файле model/train/makedfr.py в репозитории кода проекта <https://github.com/dysata/dyslexia-child>, где источником данных для обучения

предполагается локальный каталог в той же структуре как представлено в качестве примера на Hugging Face <https://huggingface.co/datasets/dysata/rwords>